

Predição de Diabetes Mellitus Tipo 2 Utilizando Técnicas de Inteligência Computacional: Uma Análise Comparativa

Rafael A. S. Ferreira
Engenharia da Computação
CEFET-MG Campus V
Divinópolis, Brasil
rafael.ferreira@aluno.cefetmg.br

João M. G. Lisboa
Engenharia da Computação
CEFET-MG Campus V
Divinópolis, Brasil
joao.lisboa@aluno.cefetmg.br

Gabriel V. Silva
Engenharia da Computação
CEFET-MG Campus V
Divinópolis, Brasil
gabriel.silva@aluno.cefetmg.br

Resumo—O Diabetes Mellitus Tipo 2 (DMT2) é um dos principais desafios de saúde pública contemporâneos, afetando mais de 537 milhões de adultos mundialmente. A identificação precoce de indivíduos em risco é fundamental para a prevenção de complicações e redução de custos hospitalares. Este trabalho conduz uma análise comparativa de quatro técnicas de Inteligência Computacional aplicadas à predição de diabetes: Multi-Layer Perceptron (MLP), Support Vector Machine (SVM), Random Forest (RF) e Regressão Logística. Utilizando o dataset PIMA Indians Diabetes, aplicamos um pipeline rigoroso de pré-processamento, incluindo tratamento de zeros impossíveis, imputação por mediana, padronização e balanceamento via SMOTE. A seleção de hiperparâmetros foi realizada por GridSearchCV com validação cruzada de 5 folds. Os resultados demonstram que a Regressão Logística obteve o melhor desempenho geral, com F1-Score de 0,656 e AUC-ROC de 0,814 no conjunto de teste, seguida pelo MLP (F1=0,623; AUC=0,812). Todos os modelos alcançaram AUC-ROC superior a 0,79, indicando capacidade discriminativa satisfatória. Os resultados evidenciam que modelos mais simples podem superar arquiteturas complexas em bases de pequeno porte.

Index Terms—Diabetes Mellitus Tipo 2, Inteligência Computacional, Aprendizado de Máquina, Multi-Layer Perceptron, Support Vector Machine, Random Forest, Regressão Logística.

I. INTRODUÇÃO

O Diabetes Mellitus Tipo 2 (DMT2) configura-se como uma das epidemias de saúde mais significativas do século XXI. Segundo o 10º Atlas da Diabetes da Federação Internacional de Diabetes (IDF), aproximadamente 537 milhões de adultos entre 20 e 79 anos viviam com a doença em 2021, com projeção de crescimento para 783 milhões até 2045 [1]. O Brasil ocupa a 6ª posição no ranking mundial de prevalência, com cerca de 16,8 milhões de indivíduos afetados [1].

A natureza progressiva e frequentemente silenciosa do DMT2 torna o diagnóstico tardio um problema recorrente. Estudos indicam que até 50% dos casos permanecem não diagnosticados por anos, período durante o qual complicações micro e macrovasculares já se instalam [2]. A capacidade de prever o risco de diabetes com antecedência, a partir de exames clínicos rotineiros, representa uma oportunidade transformadora para a medicina preventiva.

Nesse contexto, as técnicas de Inteligência Computacional (IC) emergem como ferramentas particularmente adequadas. A relação entre fatores de risco e desenvolvimento do diabetes é intrinsecamente não-linear e multivariada [3]. Algoritmos de Aprendizado de Máquina são capazes de capturar padrões sutis em dados clínicos sem a necessidade de modelagem explícita das relações entre variáveis.

O objetivo deste trabalho é realizar uma análise comparativa sistemática de quatro algoritmos de AM para predição de DMT2: MLP, SVM, Random Forest e Regressão Logística. A contribuição principal reside na avaliação rigorosa sob condições experimentais uniformes, incluindo busca exaustiva de hiperparâmetros via GridSearchCV, balanceamento de classes com SMOTE e métricas apropriadas para dados desbalanceados.

II. REVISÃO DA LITERATURA

A aplicação de técnicas de IC na predição e manejo do diabetes tem crescido substancialmente nas últimas duas décadas. Smith et al. [4] estabeleceram uma das bases mais importantes ao disponibilizar o PIMA Indians Diabetes Dataset, composto por dados clínicos de mulheres da tribo Pima, no Arizona. Esse conjunto tornou-se referência para benchmarking de algoritmos de AM em problemas de saúde.

Sisodia e Sisodia [6] conduziram um estudo comparativo utilizando Naive Bayes, k-NN e SVM no dataset PIMA, alcançando acurácia máxima de aproximadamente 77% com Naive Bayes. Maniruzzaman et al. [7] expandiram essa análise incorporando SVM com kernel RBF e Random Forest, demonstrando que esses métodos superam abordagens lineares quando adequadamente parametrizados. Kaur e Kumari [10] apresentaram uma revisão sistemática de 45 trabalhos e constataram que ensembles baseados em árvores consistentemente figuram entre os melhores desempenhos.

Apesar da quantidade crescente de trabalhos, observa-se uma lacuna: a maioria dos estudos não realiza comparações sistemáticas com busca exaustiva de hiperparâmetros nem emprega técnicas de balanceamento de forma consistente. Adicionalmente, poucos avaliam o desempenho por meio de

métricas adequadas para dados desbalanceados, como F1-Score e AUC-ROC. Este trabalho visa preencher parcialmente essa lacuna.

III. MATERIAIS E MÉTODOS

A. Descrição dos Dados

Este estudo utiliza o PIMA Indians Diabetes Database, disponibilizado pelo UCI Machine Learning Repository [4], [5]. O dataset contém 768 amostras coletadas de mulheres da tribo Pima Indian, com idade igual ou superior a 21 anos. Cada amostra possui 8 atributos numéricos preditivos e 1 variável alvo binária, conforme a Tabela I.

Tabela I
DESCRIÇÃO DOS ATRIBUTOS DO DATASET PIMA INDIANS DIABETES.

Atributo	Descrição	Tipo	Faixa Típica
NumGestacoes	Número de gestações	Numérico	0 – 17
Glicose	Concentração plasmática de glicose	Numérico	0 – 199 mg/dL
PressãoArterial	Pressão arterial diastólica	Numérico	0 – 122 mmHg
EspessuraPele	Espessura da dobra cutânea do tríceps	Numérico	0 – 99 mm
Insulina	Nível de insulina sérica	Numérico	0 – 846 mu U/mL
IMC	Índice de Massa Corporal	Numérico	0 – 67,1 kg/m ²
Pedigree	Função pedigree de diabetes	Numérico	0,078 – 2,42
Idade	Idade em anos	Numérico	21 – 81
Alvo: Diabetes	Presença de DMT2	Binário	0 / 1

O dataset apresenta desbalanceamento entre as classes: 500 instâncias (65,1%) da classe negativa e 268 instâncias (34,9%) da classe positiva. Adicionalmente, cinco atributos biológicos apresentam valores zero fisicamente impossíveis: Glicose (5 zeros), Pressão Arterial (35), Espessura da Pele (227), Insulina (374) e IMC (11). Esses valores foram interpretados como dados faltantes codificados.

B. Análise Exploratória

A análise exploratória inicial revelou as principais características do dataset. A Figura 1 apresenta o mapa de correlação entre os atributos. Observa-se que **Glicose** e **IMC** são as variáveis com maior correlação positiva com a presença de diabetes, o que é clinicamente esperado, já que ambos são fatores de risco bem estabelecidos para o DMT2. A variável **Idade** também apresenta correlação moderada com o alvo, enquanto atributos como **Espessura da Pele** e **Pressão Arterial** mostram correlações mais fracas. A alta proporção de zeros nas variáveis Insulina e Espessura da Pele evidencia a necessidade do tratamento de dados faltantes codificados.




Figura 1. Mapa de correlação entre os atributos do dataset PIMA Indians Diabetes.

C. Pré-processamento

O pipeline de pré-processamento foi executado na seguinte sequência: **(a)** zeros impossíveis foram substituídos por NaN; **(b)** valores faltantes foram imputados pela mediana calculada no conjunto de treino; **(c)** os dados foram divididos de forma estratificada em 60% treino (460 amostras), 20% validação (154) e 20% teste (154), com `random_state=42`; **(d)** aplicou-se `StandardScaler` ajustado apenas no treino; e **(e)** utilizou-se `SMOTE` exclusivamente no conjunto de treino, balanceando as classes de 300/160 para 300/300 amostras.

D. Algoritmos Avaliados

Foram avaliados quatro algoritmos de classificação, representando paradigmas distintos:

MLP – rede neural feedforward treinada por backpropagation, capaz de aproximar funções universais e capturar relações não-lineares complexas [3].

SVM – classificador que busca o hiperplano de separação ótimo maximizando a margem entre classes. Através do *kernel trick*, projeta os dados para espaços de maior dimensionalidade.

Random Forest – método de ensemble baseado em *bagging* de múltiplas árvores de decisão, conferindo robustez contra overfitting e fornecendo estimativas de importância de variáveis.

Regressão Logística – modelo linear generalizado altamente interpretável, que estima probabilidades via função logística e possui regularização integrada.

E. Configuração dos Parâmetros

A seleção de hiperparâmetros foi realizada por `GridSearchCV` com validação cruzada de 5 folds, utilizando F1-Score como métrica de otimização. Os espaços de busca definidos são apresentados a seguir.

MLP: `hidden_layer_sizes [(16,8), (32,16), (64,32)]`, `activation [relu, tanh]`, `learning_rate_init [0,001, 0,01]`, `max_iter [500]`, `early_stopping [True]`.

SVM: `C [0,1, 1, 10, 100]`, `kernel [rbf, linear]`, `gamma [scale, auto]`.

RF: `n_estimators [50, 100, 200]`, `max_depth [None, 10, 20]`, `min_samples_split [2, 5]`.

Regressão Logística: `C [0,01, 0,1, 1, 10]`, `solver [liblinear, lbfgs]`.

Os melhores parâmetros encontrados são apresentados na Tabela II.

Tabela II
MELHORES PARÂMETROS ENCONTRADOS VIA GRIDSEARCHCV.

Modelo	Melhores Parâmetros	F1 (CV)
MLP	<code>activation=relu</code> , <code>hidden_layer_sizes=(64,32)</code> , <code>lr=0,01</code>	0,778
SVM	<code>C=100</code> , <code>kernel=rbf</code> , <code>gamma=auto</code>	0,793
RF	<code>n_estimators=50</code> , <code>max_depth=None</code> , <code>min_samples_split=2</code>	0,822
LogReg	<code>C=1</code> , <code>solver=liblinear</code>	0,757

F. Procedimento Experimental

Todos os algoritmos foram avaliados sob as **mesmas condições experimentais**: mesma partição estratificada dos dados, mesmo pipeline de pré-processamento e mesmas métricas de avaliação. A divisão em treino, validação e teste foi realizada uma única vez e reproduzida de forma idêntica para todos os modelos, garantindo uma comparação justa entre as abordagens.

O GridSearchCV foi executado exclusivamente sobre o conjunto de treino (após o SMOTE), utilizando validação cruzada de 5 folds para seleção dos hiperparâmetros. O conjunto de validação (20%) foi reservado para aferição final dos modelos candidatos durante a busca em grade. Por fim, o conjunto de **teste foi utilizado apenas uma única vez para a avaliação final**, sem influenciar qualquer etapa de treinamento, validação ou seleção de hiperparâmetros. Essa prática evita vazamento de informação (data leakage) e assegura que as métricas reportadas reflitam a capacidade de generalização real dos modelos.

G. Métricas de Avaliação

Considerando o desbalanceamento das classes, foram empregadas: acurácia, precisão, revocação, F1-Score e AUC-ROC. Modelos estocásticos (MLP e RF) foram executados 10 vezes com diferentes sementes aleatórias, reportando média $\pm$ desvio-padrão. SVM e Regressão Logística, por serem determinísticos, foram executados uma única vez.

IV. RESULTADOS E DISCUSSÃO

A. Desempenho dos Modelos

A Tabela III apresenta os resultados obtidos no conjunto de teste. A Regressão Logística obteve o melhor F1-Score (0,656) e AUC-ROC (0,814), seguida pelo MLP (F1=0,623; AUC=0,812). Todos os modelos alcançaram AUC-ROC superior a 0,79.

Tabela III
RESULTADOS DE DESEMPENHO NO CONJUNTO DE TESTE (MÉDIA $\pm$ DESVIO-PADRÃO, N=10).

Modelo	Acurácia	Precisão	Revocação	F1-Score	AUC-ROC
MLP	0,718 $\pm$ 0,012	0,587 $\pm$ 0,017	0,667 $\pm$ 0,050	0,623 $\pm$ 0,023	0,812 $\pm$ 0,007
SVM	0,721	0,604	0,593	0,598	0,792
RF	0,733 $\pm$ 0,012	0,619 $\pm$ 0,016	0,622 $\pm$ 0,026	0,620 $\pm$ 0,020	0,808 $\pm$ 0,004
LogReg	0,734	0,600	0,722	0,656	0,814

A Tabela IV apresenta as matrizes de confusão consolidadas no conjunto de teste. A Regressão Logística apresentou o maior número de verdadeiros positivos (39) e o menor de falsos negativos (15), confirmando sua superioridade em identificar corretamente pacientes diabéticos.

Tabela IV
MATRIZ DE CONFUSÃO NO CONJUNTO DE TESTE.

Modelo	VP	VN	FP	FN
MLP	40	73	27	14
SVM	32	79	21	22
RF	32	80	20	22
LogReg	39	74	26	15

B. Impacto dos Hiperparâmetros

A busca em grade revelou comportamentos importantes. O MLP obteve melhor desempenho com arquitetura moderada (64,32) e `learning_rate_init=0,01`, enquanto arquiteturas menores ou taxas de aprendizado mais baixas resultaram em menor F1 na validação cruzada. O SVM selecionou `C=100` e kernel RBF, indicando necessidade de fronteira de decisão flexível; contudo, essa mesma flexibilidade pode ter causado overfitting no conjunto de teste. O Random Forest preferiu apenas 50 árvores e profundidade ilimitada, sugerindo que o aumento do número de árvores não compensou a restrição imposta pelo pequeno dataset. A Regressão Logística selecionou `C=1`, ponto intermediário de regularização L2 que balanceou bem viés e variância.

C. Análise por Modelo

A Regressão Logística obteve desempenho superior apesar de sua simplicidade, o que pode ser atribuído à escassez de dados (apenas 460 amostras de treino pré-SMOTE), condição em que modelos com menos parâmetros tendem a generalizar melhor [8]. Sua revocação de 0,722 – a mais alta entre os modelos – é crítica em contextos de saúde, onde falsos negativos têm consequências mais graves.

O MLP obteve o segundo melhor F1-Score (0,623), com AUC-ROC competitivo (0,812). Contudo, apresentou a maior variabilidade entre execuções (desvio-padrão de 0,023 no F1-Score), evidenciando sensibilidade à inicialização aleatória dos pesos.

O Random Forest apresentou desempenho estável (menor desvio-padrão entre os modelos estocásticos: 0,020 no F1-Score), mas limitado em magnitude. A análise de importância de variáveis revelou que Glicose e IMC são, por larga margem, os atributos mais discriminativos, resultado consistente com o conhecimento clínico.

O SVM obteve o menor F1-Score (0,598). Apesar da flexibilidade do kernel RBF, a alta regularização ($C=100$) combinada com o pequeno volume de treino pode ter levado a um modelo excessivamente flexível.

D. Visualização dos Resultados

A Figura 2 apresenta as curvas ROC dos modelos, destacando a capacidade discriminativa semelhante entre Regressão Logística e MLP. A Figura 3 compara as principais métricas, reforçando a superioridade da Regressão Logística no F1-Score. A Figura 4 mostra a importância relativa das variáveis preditoras segundo o Random Forest.




Figura 2. Curvas ROC dos modelos no conjunto de teste.




Figura 3. Comparação de acurácia, F1-Score e AUC-ROC.




Figura 4. Importância das variáveis preditoras – Random Forest.

E. Discussão Geral

Todos os modelos alcançaram AUC-ROC superior a 0,79, indicando capacidade discriminativa satisfatória segundo os critérios de Hosmer e Lemeshow [9]. O F1-Score relativamente modesto (0,598 a 0,656) reflete a dificuldade intrínseca da predição a partir de oito variáveis clínicas, sem acesso a marcadores bioquímicos mais específicos.

A comparação com resultados reportados na literatura mostra consistência. Sisodia e Sisodia [6] reportaram acurácia de aproximadamente 77% com Naive Bayes no mesmo dataset, valor comparável à acurácia de 73% observada neste estudo. Maniruzzaman et al. [7] reportaram AUC-ROC entre 0,80 e 0,85 para SVM e Random Forest, faixa compatível com os nossos resultados.

O predomínio da Regressão Logística sobre abordagens mais sofisticadas reforça o princípio de que a complexidade do modelo deve estar adequada à quantidade e qualidade dos dados disponíveis [3]. Em bases de pequeno porte com alta dimensionalidade relativa, modelos lineares regularizados frequentemente superam arquiteturas não-lineares.

V. CONCLUSÃO

Este trabalho apresentou uma análise comparativa sistemática de quatro técnicas de Inteligência Computacional – MLP, SVM, Random Forest e Regressão Logística – aplicadas à predição de Diabetes Mellitus Tipo 2 utilizando o dataset PIMA Indians Diabetes. A metodologia empregou um pipeline rigoroso de pré-processamento, balanceamento via SMOTE e busca exaustiva de hiperparâmetros por GridSearchCV.

Os resultados demonstram que a Regressão Logística obteve o melhor desempenho geral, com F1-Score de 0,656 e AUC-ROC de 0,814, superando modelos mais complexos. Todos os algoritmos avaliados alcançaram AUC-ROC superior a 0,79, indicando capacidade discriminativa satisfatória.

As principais limitações incluem: (i) o tamanho reduzido do dataset (768 amostras); (ii) a especificidade demográfica dos dados (mulheres da tribo Pima); (iii) a imputação de zeros pode introduzir viés; e (iv) a ausência de variáveis como HbA1c e perfil lipídico. Como trabalhos futuros, sugere-se a avaliação com datasets de maior volume, a exploração de mo-

delos ensemble híbridos e a implementação de explicabilidade via SHAP e LIME.

REFERÊNCIAS

- [1] International Diabetes Federation, “IDF Diabetes Atlas,” 10th ed., Brussels, 2021.
- [2] I. Kavakiotis et al., “Machine learning and data mining methods in diabetes research,” *Comput. Struct. Biotechnol. J.*, vol. 15, pp. 104–116, 2017.
- [3] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Pearson, 2009.
- [4] J. W. Smith et al., “Using the ADAP learning algorithm to forecast the onset of diabetes mellitus,” in *Proc. Annu. Symp. Comput. Appl. Med. Care*, 1988, pp. 261–265.
- [5] UCI Machine Learning Repository, “Pima Indians Diabetes Database,” 2024. [Online]. Available: <https://archive.ics.uci.edu/ml/datasets/diabetes>
- [6] D. Sisodia e D. S. Sisodia, “Prediction of diabetes using classification algorithms,” *Procedia Comput. Sci.*, vol. 132, pp. 1578–1585, 2018.
- [7] M. Maniruzzaman et al., “Classification and prediction of diabetes disease using machine learning paradigm,” *Health Inf. Sci. Syst.*, vol. 5, no. 1, pp. 1–14, 2017.
- [8] S. Russel e P. Norvig, *Inteligência Artificial: Uma Abordagem Moderna*, 4th ed. GEN LTC, 2021.
- [9] D. W. Hosmer, S. Lemeshow e R. X. Sturdivant, *Applied Logistic Regression*, 3rd ed. Wiley, 2013.
- [10] H. Kaur e V. Kumari, “Predictive modelling and analytics for diabetes using a machine learning approach,” *Appl. Comput. Inform.*, vol. 18, no. 1-2, pp. 90–100, 2021.