

Predição de Diabetes Mellitus Tipo 2 Utilizando Técnicas de Inteligência Computacional

Uma Análise Comparativa

Rafael A. S. Ferreira João M. G. Lisboa Gabriel V. Silva
CEFET-MG — Inteligência Computacional

Centro Federal de Educação Tecnológica de Minas Gerais
Campus V — Divinópolis

Junho de 2026

- 1 Introdução
- 2 Dataset e Pré-processamento
- 3 Algoritmos e Metodologia
- 4 Resultados
- 5 Discussão e Conclusões

- O Diabetes Mellitus Tipo 2 (DMT2) é uma das principais epidemias de saúde do século XXI.
- Mais de **537 milhões** de adultos viviam com a doença em 2021 (IDF).
- No Brasil, cerca de **16,8 milhões** de pessoas são afetadas.
- Até 50% dos casos permanecem não diagnosticados por anos.
- A predição precoce permite intervenções preventivas e redução de custos hospitalares.

Por que Inteligência Computacional?

A relação entre fatores de risco e diabetes é **não-linear e multivariada**, tornando-a adequada para técnicas de Aprendizado de Máquina.

Realizar uma análise comparativa sistemática de quatro algoritmos de Inteligência Computacional para predição de DMT2:

- **MLP** – Multi-Layer Perceptron
- **SVM** – Support Vector Machine
- **Random Forest**
- **Regressão Logística**

Foco

Avaliação rigorosa sob condições experimentais uniformes: mesma divisão dos dados, busca em grade de hiperparâmetros, balanceamento com SMOTE e métricas apropriadas para dados desbalanceados.


Dataset PIMA Indians Diabetes

- **Fonte:** UCI Machine Learning Repository.
- **Amostras:** 768 mulheres da tribo Pima Indian (Arizona, EUA), idade ≥ 21 anos.
- **Atributos:** 8 variáveis numéricas preditivas.
- **Alvo:** presença (1) ou ausência (0) de DMT2.
- **Desbalanceamento:** 65,1% negativos e 34,9% positivos.

Atributo	Descrição	Zeros impossíveis
NumGestacoes	Número de gestações	—
Glicose	Concentração plasmática de glicose	5
Pressão Arterial	Pressão diastólica	35
Espessura da Pele	Dobra cutânea do tríceps	227
Insulina	Nível sérico de insulina	374
IMC	Índice de Massa Corporal	11
Pedigree	Histórico familiar	—
Idade	Idade em anos	—

Pipeline de Pré-processamento

- 1 **Tratamento de zeros impossíveis:** substituídos por NaN e imputados pela mediana do treino.
- 2 **Divisão estratificada:** 60% treino (460), 20% validação (154), 20% teste (154).
- 3 **Padronização:** StandardScaler ajustado apenas no treino.
- 4 **Balanceamento:** SMOTE apenas no treino (300/300 amostras).



MLP

Rede neural feedforward com backpropagation; capaz de capturar relações não-lineares complexas.

SVM

Busca o hiperplano de separação ótimo; kernel RBF projeta dados para espaços de maior dimensionalidade.

Random Forest

Ensemble de árvores de decisão via *bagging*; robusto contra overfitting e fornece importância de variáveis.

Regressão Logística

Modelo linear generalizado altamente interpretável, com regularização L1/L2 integrada.

Configuração dos Experimentos

- **Seleção de hiperparâmetros:** GridSearchCV com validação cruzada de 5 folds.
- **Métrica de otimização:** F1-Score.
- **Repetições:** 10 execuções independentes para MLP e Random Forest.
- **Métricas de avaliação:** acurácia, precisão, revocação, F1-Score e AUC-ROC.

Modelo	Principais parâmetros testados	Melhor F1 (CV)
MLP	camadas, ativação, learning rate	0,778
SVM	C, kernel, gamma	0,793
RF	n_estimators, max_depth, min_samples_split	0,822
LogReg	C, solver	0,757

Resultados de Desempenho



Modelo	Acurácia	Precisão	Revocação	F1	AUC-ROC
MLP	$0,718 \pm 0,012$	$0,587 \pm 0,017$	$0,667 \pm 0,050$	$0,623 \pm 0,023$	$0,812 \pm 0,007$
SVM	0,721	0,604	0,593	0,598	0,792
RF	$0,733 \pm 0,012$	$0,619 \pm 0,016$	$0,622 \pm 0,026$	$0,620 \pm 0,020$	$0,808 \pm 0,004$
LogReg	0,734	0,600	0,722	0,656	0,814

Destaque


A **Regressão Logística** obteve o melhor F1-Score (0,656) e AUC-ROC (0,814), superando modelos mais complexos.

Matriz de Confusão

Modelo	VP	VN	FP	FN
MLP	40	73	27	14
SVM	32	79	21	22
RF	32	80	20	22
LogReg	39	74	26	15



Importância das Variáveis



- **Regressão Logística** venceu apesar da simplicidade: escassez de dados favorece modelos com menos parâmetros e regularização adequada.
- **MLP** foi o segundo melhor, mas apresentou maior variabilidade entre execuções (sensibilidade à inicialização).
- **Random Forest** foi estável, mas limitado em magnitude; destacou Glicose e IMC como principais preditores.
- **SVM** obteve o menor F1; a alta regularização ($C=100$) pode ter causado overfitting no pequeno conjunto de treino.
- Todos os modelos alcançaram $AUC-ROC > 0,79$, indicando capacidade discriminativa satisfatória.

Conclusões:

- Pipeline completo e reprodutível de ML para predição de DMT2.
- Modelo mais simples (Regressão Logística) superou arquiteturas complexas neste dataset de pequeno porte.
- AUC-ROC superior a 0,79 para todos os modelos valida a relevância das variáveis clínicas.

Trabalhos futuros:

- Avaliação com datasets maiores e dados hospitalares brasileiros.
- Exploração de modelos ensemble híbridos.
- Uso de técnicas de explicabilidade (SHAP, LIME) para adoção clínica.

-  International Diabetes Federation, “IDF Diabetes Atlas,” 10th ed., Brussels, 2021.
-  I. Kavakiotis et al., “Machine learning and data mining methods in diabetes research,” *Comput. Struct. Biotechnol. J.*, vol. 15, pp. 104–116, 2017.
-  S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Pearson, 2009.
-  J. W. Smith et al., “Using the ADAP learning algorithm to forecast the onset of diabetes mellitus,” in *Proc. Annu. Symp. Comput. Appl. Med. Care*, 1988, pp. 261–265.
-  D. Sisodia e D. S. Sisodia, “Prediction of diabetes using classification algorithms,” *Procedia Comput. Sci.*, vol. 132, pp. 1578–1585, 2018.
-  M. Maniruzzaman et al., “Classification and prediction of diabetes disease using machine learning paradigm,” *Health Inf. Sci. Syst.*, vol. 5, no. 1, pp. 1–14, 2017.

Agradecimento

Agradecemos ao Prof. Dr. Alisson Marques da Silva pela orientação na disciplina de Inteligência Computacional.

Obrigado!

Dúvidas?

`rafael.ferreira@aluno.cefetmg.br`